

Nombre y Apellidos: Guadalupe Martínez Blanco

Github con notebook: <https://github.com/gmblanco/job-skill-wage-dashboard/tree/main>

El archivo se llama: **DAVD_Examen_final_2025_2026_guadalupe_martinez.ipynb**

1. Resumen Ejecutivo

El objetivo del análisis consiste en analizar el comportamiento del gasto sanitario y la salud de los asegurados con modelos predictivos orientados a identificar pacientes de alto riesgo clínico. Además, se busca facilitar decisiones estratégicas sobre gestión del riesgo, contención de costes y priorización de intervenciones así como ajustar los seguros al riesgo clínico de los pacientes y a su respectivo coste anual.

Principales hallazgos:

- 1) El coste médico está muy concentrado en un pequeño grupo de pacientes


La mayoría de los asegurados presentan costes relativamente bajos (< 5.000 € anuales), pero existe un pequeño conjunto que genera la mayor parte del gasto. En este grupo es en el que hay que centrarse porque son los que mayor coste anual tienen.

- 2) El coste aumenta claramente con la edad

El gasto sanitario crece de forma sostenida a partir de los 40 años y se acelera especialmente después de los 60.

Esto refleja que cuanto mayor sea la persona es más propensa a tener una enfermedad crónica, presión arterial elevada y necesidad de intervenciones.

- 3) Además durante el análisis se ha desarrollado el siguiente dashboard:



El dashboard integra las cuatro visualizaciones clave para entender la estructura del gasto y los factores asociados al riesgo. Se puede ver, como se ha comentado antes que la gran mayoría de pacientes no tienen un coste anual muy grande a excepción de un pequeño grupo.

También se puede ver que el coste anual presenta un incremento progresivo, especialmente en mayores de 60.

En cuanto a la importancia de las variables del modelo de Random Forest realizado, se puede observar que las variables como la edad, presión arterial, salud mental, hábito de fumar y artritis son los principales impulsores del riesgo clínico.

Para la predicción del riesgo clínico se han elaborado 2 modelos de clasificación, uno de random forest y otro de regresión logística. En ambos se ha obtenido una accuracy muy alta y parámetros de predicción elevados.

La precisión del modelo de Random Forest fue del 99% y la de la regresión logística del 97%. Ambos confirman la solidez de las relaciones entre variables clínicas y riesgo.

La razón de haber implementado un modelo de regresión logística fue para ver la correlación tanto positiva como negativa en la variable objetivo.

Mediante este análisis se puede ver que los factores que más incrementan la probabilidad de ser alto riesgo son:

- Edad avanzada
- Presión arterial
- Salud mental deteriorada
- Ser fumador habitual
- Artritis e hipertensión

Por el contrario:

Ser no fumador o exfumador reduce el riesgo.

Recomendaciones

Tras realizar el análisis exhaustivo recomiendo lo siguiente:

- 1) Focalizar recursos en el pequeño grupo de pacientes de alto coste: una forma de hacer esto sería por ejemplo implementando programas específicos de gestión intensiva (seguimiento, case managers, telecontrol) para este grupo.
- 2) Implementar estrategias dirigidas a mayores de 60 años o para el caso de la aseguradora darles planes específicos: Al ser un grupo con mayor progresión del coste y mayor riesgo de padecer enfermedades crónicas, la aseguradora podría por

tanto centrarse más es este grupo y darles precios de primas más ajustados a su riesgo.


- 3) Identificar y tratar condiciones clínicas clave que favorecen un mayor riesgo clínico como la artritis, problemas de salud mental y niveles alterados de presión arterial, pues son fuertes predictores de alto riesgo.
- 4) Campañas dirigidas a fumadores: Aunque hemos visto que el hábito de fumar no predice por sí solo el coste total, sí aumenta significativamente el riesgo clínico. Por tanto se podría hacer un seguimiento a este tipo de pacientes.

Por tanto, este análisis muestra que el riesgo clínico y los costes sanitarios pueden predecirse con alta precisión utilizando datos clínicos básicos, biomarcadores y señales demográficas.

Con este conocimiento, la aseguradora puede priorizar intervenciones preventivas, optimizar la asignación de recursos y mejorar la calidad del servicio, enfocándose en los factores que realmente impulsan el riesgo y el coste anual.

2. Gráficas del análisis exploratorio y breve explicación de cada una


Gráfica 1



En esta primera gráfica se puede observar la distribución del coste médico anual. Como se puede observar en ella, la mayor parte del gasto anual proviene de un pequeño grupo de pacientes con costes muy elevados, lo que sugiere que gestionar a estos casos de alto consumo puede tener un gran impacto económico.

Por otro lado, se puede ver que para la mayoría de los casos el coste anual es menor de los 5000 euros.

Gráfica 2




En el anterior gráfico de correlación podemos observar que los atributos más relacionados con la variable objetivo `is_high_risk` son principalmente el `risk_score` que tiene una fuerte correlación positiva, esto tiene sentido pues es el medidor principal de si hay alto riesgo y por otro lado hay variables que tienen una fuerte correlación negativa como: `copay`, `policy_term_years`, `policy_changes_last_2yrs`, etc.

El heatmap por tanto revela tres grandes grupos de variables: por un lado costes y reclamaciones, por otra utilización de servicios, y por otras condiciones clínicas. Los costes médicos y el gasto total pagado se correlacionan fuertemente con las reclamaciones y las primas, mientras que el riesgo clínico y el número de crónicas se relacionan con una mayor utilización de servicios. `is_high_risk` está principalmente asociado al riesgo clínico, presencia de múltiples enfermedades crónicas y mayores costes sanitarios.


Por otro lado podemos ver que para el anual medial cost influye mucho el anual premium y el monthly premium.

Gráfico 3




En el anterior gráfico se ha representado el coste medico anual promedio por nivel educativo. Sin embargo, el nivel educativo no parece ser un factor determinante del coste médico anual en este dataset. Aunque hay pequeñas variaciones, los costes se mantienen muy estables entre todos los niveles educativos.

Gráfico 4




En la gráfica anterior se puede ver claramente que el coste médico aumenta de forma progresiva y significativa con la edad, especialmente a partir de los 60 años. Esto tiene sentido y nos indica que los adultos mayores son, en promedio, el grupo que más gasto sanitario genera, lo que coincide con un mayor riesgo clínico y mayor presencia de enfermedades crónicas.

Gráfico 5

En la anterior gráfica se puede observar que pasado el umbral de los 25000 euros aproximadamente el riesgo alto es mucho mayor, lo que indica que las operaciones de mayor coste suelen ser las más arriesgadas.

Por tanto, podemos ver que el riesgo clínico es un fuerte predictor del coste médico anual. Los pacientes identificados como “alto riesgo” no solo presentan scores significativamente mayores, sino que generan costes mucho más altos y variables, con presencia de múltiples outliers. Este patrón nos enseña la utilidad del risk_score como herramienta para priorizar intervenciones, control de crónicos y gestión del gasto sanitario.

Gráfico 6

El hábito de fumar no aparece como un determinante directo del coste médico anual en esta muestra.

Aunque fumar es un factor de riesgo alto, su impacto en el coste total queda eclipsado por

otras variables más fuertes como el número de enfermedades crónicas, el riesgo clínico y las hospitalizaciones. Además se puede ver que quedan fuera muchos outliers en los boxplots.

3. Modelo predictivo explicado y con tablas

Se ha elegido hacer un modelo predictivo de clasificación de Machine Learning para tratar de predecir la variable `is_high_risk`, indicadora del alto riesgo.

Para ello he elegido usar un random forest porque es muy bueno para problemas de clasificación en datos tabulares con muchas variables clínicas, demográficas y de hábitos. Además es muy robusto y evita el overfitting, lo que permite interpretar qué factores contribuyen más al riesgo clínico.

Al comenzar el preprocesado del modelo se han elegido únicamente las variables relacionadas con costes y reclamaciones, utilización de servicios y las derivadas del riesgo.

```
variables_fuera = [
    # Costes y reclamaciones
    "annual_medical_cost", "annual_premium", "monthly_premium",
    "total_claims_paid", "claims_count", "avg_claim_amount",

    # Utilización de servicios
    "visits_last_year", "hospitalizations_last_3yrs",
    "days_hospitalized_last_3yrs", "medication_count",
    "proc_imaging_count", "proc_surgery_count", "proc_physio_count",
    "proc_consult_count", "proc_lab_count", "had_major_procedure",

    # Derivadas de riesgo
    "risk_score", "chronic_count"
]
```

Se han eliminado estas variables para asegurar que el modelo utiliza únicamente información disponible antes de la clasificación del riesgo, garantizando un modelo realista, válido y generalizable para uso en la práctica aseguradora.

Después se ha separado en training y test en una proporción 80% 20% y se han logrado obtener los siguientes resultados:

```
Accuracy: 0.98765
F1 Score: 0.9831318718841767
```

```
Classification report:
              precision    recall  f1-score   support

     0           0.98       1.00       0.99       12599
     1           0.99       0.97       0.98        7401

 accuracy              0.99       0.98       0.99       20000
 macro avg              0.99       0.98       0.99       20000
 weighted avg           0.99       0.99       0.99       20000
```

El modelo entrenado obtiene un rendimiento muy elevado porque utiliza variables clínicas, demográficas y de estilo de vida que están fuertemente asociadas al riesgo real de los pacientes. Estas variables proporcionan al modelo información relevante y no filtrada que

permite diferenciar con gran precisión entre pacientes de bajo y alto riesgo, logrando métricas cercanas al 99%.

Se ha obtenido una precisión del 99%, lo cual es muy buena, al igual que una alta diferenciación entre las clases 0 y 1 de `high_risk`, lo que indica que sabe distinguir cuando nos encontramos ante un caso de alto riesgo y cuando no.

	feature	importance
0	age	0.316230
5	systolic_bp	0.083131
49	smoker_Current	0.063950
23	mental_health	0.060318
22	arthritis	0.051624
14	hypertension	0.048558
4	bmi	0.037058
6	diastolic_bp	0.036776
8	hba1c	0.030138
16	asthma	0.027336
15	diabetes	0.026287
18	cardiovascular_disease	0.023953
17	copd	0.016510
7	ldl	0.014399
51	smoker_Never	0.014373
1	income	0.013900
13	provider_quality	0.013250
50	smoker_Former	0.010923
19	cancer_history	0.009007
11	policy_term_years	0.008042

Por último, se han impreso en una tabla las variables junto con su grado de importancia. Se ha podido ver que las variables que más influyen al alto riesgo son la edad principalmente, la salud mental, si nos encontramos a una persona que es fumador habitual y la presión en sangre.

Después se ha visto cómo cambia el modelo si se opta por una regresión logística. Para ello se ha seguido el mismo procedimiento y se ha obtenido la siguiente tabla de `accuracy`:

Por último se ha visto que parámetros son los que mas afectan a `is_high_risk`, resultando los siguientes:


Accuracy: 0.97275

F1 Score: 0.9629327348160239

Classification report:

	precision	recall	f1-score	support
0	0.98	0.98	0.98	12644
1	0.96	0.96	0.96	7356
accuracy			0.97	20000
macro avg	0.97	0.97	0.97	20000
weighted avg	0.97	0.97	0.97	20000

Vemos que los resultados siguen siendo muy buenos para una regresión logística, obteniendo una accuracy del 97%.



Los que tienen un mayor impacto positivo en la variable objetivo son la edad, al igual que se vio en el modelo anterior, y si la persona es un fumador habitual. Seguidas de la hipertensión, la salud mental y la artritis.

Por otro lado las que menos afectan (correlación negativa) son si la persona no fuma y si es antiguo fumador.